AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE
AGH UNIVERSITY OF KRAKOW

Klasyfikacja obrazów na FPGA z użyciem Vitis AI

06.11.2025

Problem

- Klasyfikacja obrazów z datasetu CIFAR-10
  - 60000 obrazków 32x32 piksele
  - 10 klas – Samochody, samoloty itd.
- Celem jest sprawdzenie jak kwantyzacja i implementacja na FPGA wpływa na czas inferencji I dokładność modelu.

Zalety Machine Learningu na FPGA

- Niskie opóźnienia
- Bardzo dobra wydajność
- Dobry stosunek cena/jakość
- Niskie zużycie energii

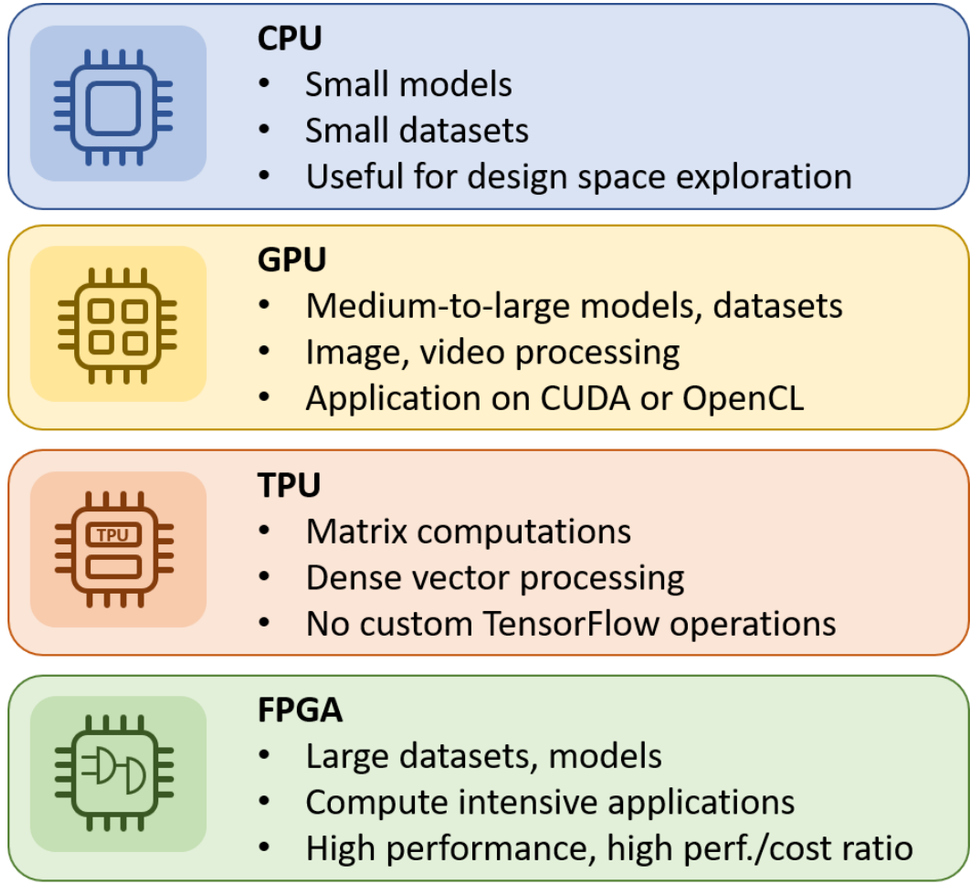

Kwantyzacja

- Kwantyzacja pozwala na znaczne zmniejszenie modelu i jego przyśpieszenie kosztem minimalnego spadku na dokładności.

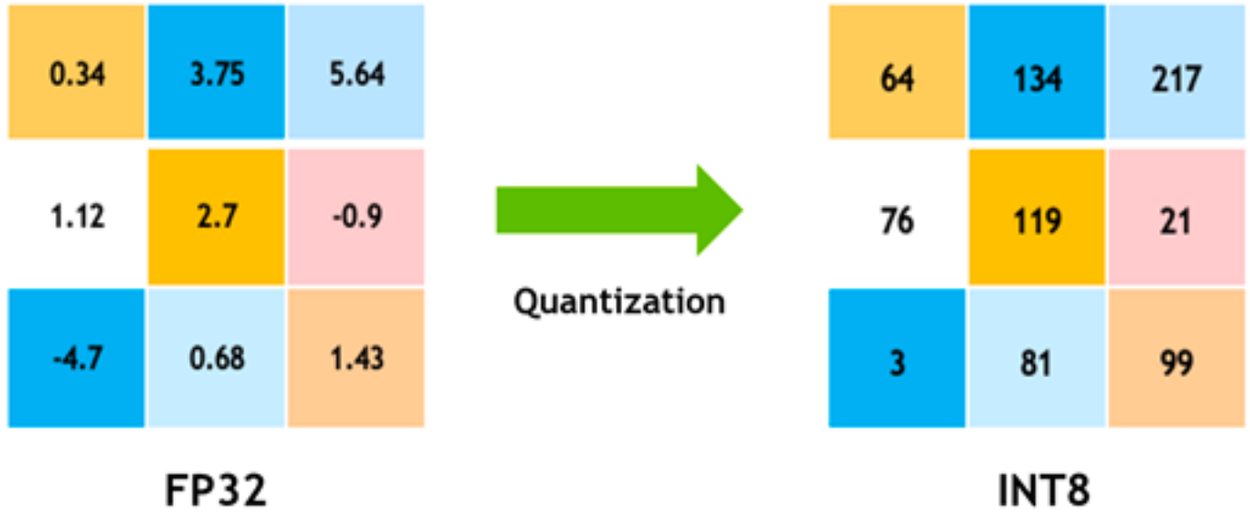

Vitis AI

- Zintegrowane środowisko do rozwoju aplikacji AI na platformach AMD
- Zawiera narzędzia, biblioteki oraz gotowe modele i przykłady

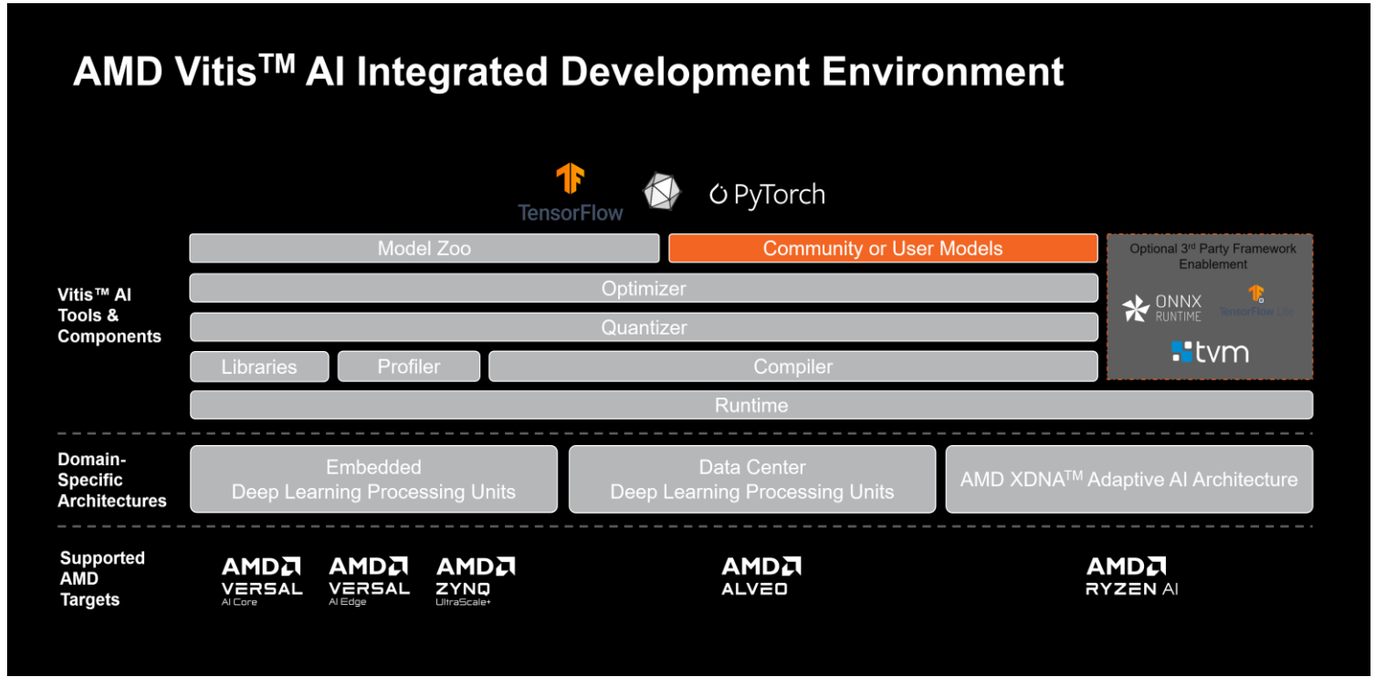

Etapy pracy

- Trenowanie modelu w PyTorch
  - MobileNetV2 na zbiorze CIFAR-10
- Eksport do ONNX
  - torch.onnx.export(model, input, "model.onnx")
- Kwantyzacja
  - Użycie Vitis AI Quantizer (vai_q_pytorch) do konwersji na INT8
- Kompilacja
  - Kompilacja modelem w Vitis AI Compiler pod konkretną platformę FPGA
- Uruchomienie inferencji
  - Wykorzystanie Vitis AI Runtime (VART) do wykonania na FPGA

Wyniki

- Trenowanie modelu w PyTorch
  - MobileNetV2 na zbiorze CIFAR-10

```
Epoka 1/5
  Train: loss=0.4381, acc=84.98%
  Test : loss=0.3200, acc=88.84%
Epoka 2/5
  Train: loss=0.2711, acc=90.70%
  Test : loss=0.3129, acc=89.58%
Epoka 3/5
  Train: loss=0.2248, acc=92.38%
  Test : loss=0.2680, acc=90.97%
Epoka 4/5
  Train: loss=0.1938, acc=93.36%
  Test : loss=0.2668, acc=91.08%
Epoka 5/5
  Train: loss=0.1699, acc=94.09%
  Test : loss=0.2888, acc=90.81%
```

Wyniki

- ~~Eksport do ONNX~~
  - ~~torch.onnx.export(model, input, "model.onnx")~~

```
[torch.onnx] Obtain model graph for `MobileNetV2([...]` with `torch.export.export(..., strict=False)`...
[torch.onnx] Obtain model graph for `MobileNetV2([...]` with `torch.export.export(..., strict=False)`... ✅
[torch.onnx] Run decomposition...
[torch.onnx] Run decomposition... ✅
[torch.onnx] Translate the graph into ONNX...
[torch.onnx] Translate the graph into ONNX... ✅
Applied 104 of general pattern rewrite rules.
Model wyeksportowany do mobilenetv2_cifar10.onnx
```

- Eksport pyTorch (plik *.pt)

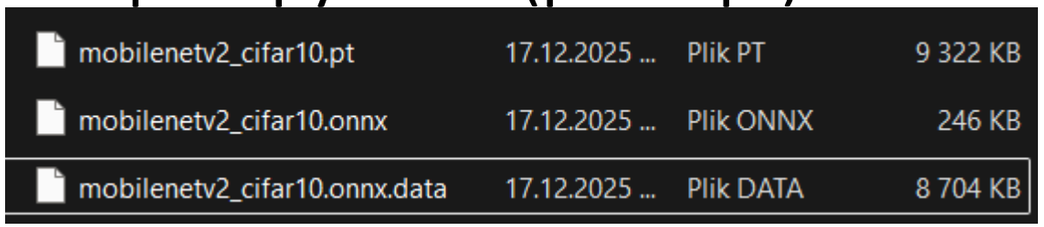

Wyniki

- Vitis AI ☹

Źródła

- https://my.avnet.com/silica/resources/article/fpga-vs-gpu-vs-cpu-hardware-options-for-ai-applications/
- https://xilinx.github.io/Vitis-AI/3.5/html/index.html